HEP CONFERENCE HUB

Documentação técnica completa do portal

Congressos, workshops e escolas em Física de Altas Energias

Arquitetura, implementação, coleta de dados, auditoria, implantação e expansão para a América Latina

Responsável pelo projeto: Nelson Cevidanes Nascimento de Assis

Versão documentada: prioridades 1 a 5 e expansão latino-americana

Data de referência: 26 de julho de 2026

2026

CONTROLE DO DOCUMENTO

Item	Descrição
Título	Documentação técnica do HEP Conference Hub
Versão	1.0
DOI da versão 1.0.0: 10.5281/zenodo.21611863	26/07/2026
Data de referência	
Estado funcional	Portal em execução com API, frontend, banco, fila, crawler e catálogo latino-americano
Escopo coberto	Prioridades 1–5, expansão regional e procedimentos operacionais
Pendência estrutural	Prioridade 6: arquivo histórico pesquisável de eventos concluídos

Nota de rastreabilidade. Este documento consolida a arquitetura, as decisões e os procedimentos efetivamente desenvolvidos durante a implementação. Alguns detalhes operacionais podem variar conforme novas alterações no repositório; os comandos de validação apresentados devem ser usados para confirmar o estado real da instalação.

SUMÁRIO

Controle do documento 1

1 VISÃO GERAL E OBJETIVOS 6
1.1 Público-alvo 6
1.2 Princípios de projeto 6

2 EVOLUÇÃO DA IMPLEMENTAÇÃO POR PRIORIDADES 8
2.1 Estratégia incremental 8

3 REQUISITOS FUNCIONAIS E NÃO FUNCIONAIS 10
3.1 Requisitos funcionais 10
3.2 Requisitos não funcionais 10

4 ARQUITETURA DO SISTEMA 12
4.1 Serviços principais 12
4.2 Fluxo de dados 13

5 TECNOLOGIAS UTILIZADAS 14
5.1 Compatibilidade Scrapy/Twisted 14

6 ORGANIZAÇÃO DO REPOSITÓRIO 15
6.1 Responsabilidades por diretório 15

7 MODELO DE DADOS 17
7.1 Event 17
7.2 CallForPapers / chamadas 17
7.3 RegistrationWindow 17
7.4 EventResource 17
7.5 VerificationMixin 18
7.6 Estados independentes 18

8 API REST 19
8.1 Endpoints principais 19
8.2 Filtros de consulta 19
8.3 Exemplo de consulta regional 19
8.4 Estrutura resumida da resposta 20

9 FRONTEND WEB 21
9.1 Elementos de interface 21
9.2 EventCard 21
9.3 Exemplo de apresentação 21

10 CRAWLER E EXTRAÇÃO DE INFORMAÇÕES 22
10.1 Configurações responsáveis 22
10.2 Descoberta semântica de páginas 22
10.3 Extração de prazos 22
10.4 Conflitos 22
10.5 Spiders 23
10.6 Saídas 23

11 PROCESSAMENTO ASSÍNCRONO 24
11.1 Cuidados operacionais 24

12 CATÁLOGO E EXPANSÃO PARA A AMÉRICA LATINA 25
12.1 Eventos centrais cadastrados 25

12.2 Fontes de descoberta . . . 25
12.3 Regra de publicação . . . 26

13 AUDITORIA, CONFIANÇA E RASTREABILIDADE . . . 27
13.1 Confiança . . . 27
13.2 Recência . . . 27
13.3 Evidência mínima . . . 27

14 TESTES E GARANTIA DA QUALIDADE . . . 29
14.1 Grupos de testes . . . 29
14.2 Comando de teste . . . 29
14.3 Critérios de aceitação . . . 29

15 DOCKER, CONFIGURAÇÃO E IMPLANTAÇÃO . . . 31
15.1 Variáveis de ambiente . . . 31
15.2 Construção e subida . . . 31
15.3 Seed . . . 31
15.4 Preservação do banco . . . 31
15.5 Reconstrução seletiva . . . 31

16 OPERAÇÃO DIÁRIA . . . 32
16.1 Verificação de serviços . . . 32
16.2 Consulta de eventos latino-americanos . . . 32
16.3 Ambiente local do crawler . . . 32
16.4 Coleta regional . . . 32

17 PROBLEMAS ENCONTRADOS E CORREÇÕES . . . 34
17.1 Procedimento seguro para substituição da árvore . . . 35

18 SEGURANÇA, ÉTICA E CONFORMIDADE . . . 36
18.1 Riscos de dados . . . 36

19 LIMITAÇÕES ATUAIS E ROADMAP . . . 37
19.1 Limitações . . . 37
19.2 Prioridade 6 . . . 37
19.3 Melhorias recomendadas . . . 37

Appendices 38

A – SEQUÊNCIA DE INSTALAÇÃO LIMPA . . . 39

B – CHECKLIST DE RELEASE 40

C – GLOSSÁRIO 41

D – REFERÊNCIA RÁPIDA DE COMANDOS 42

LISTA DE ILUSTRAÇÕES

Figura 1 – Arquitetura lógica do portal. 12
Figura 2 – Fluxo da descoberta à publicação. 13

1 VISÃO GERAL E OBJETIVOS

O HEP Conference Hub é um portal destinado a localizar, organizar, acompanhar e auditar eventos científicos relacionados à Física de Altas Energias (HEP), calorimetria, detectores, aceleradores, computação científica, cosmologia e astropartículas. O sistema foi projetado para reduzir a dispersão de informações entre páginas oficiais, plataformas Indico, sites de institutos, agendas regionais e páginas de colaboração.

O portal procura responder, em uma única interface, às seguintes perguntas:

- Quais eventos estão próximos, em andamento ou concluídos?
- A submissão de resumos está aberta, encerrada ou ainda não anunciada?
- A inscrição está aberta e quais são os prazos antecipado, regular ou presencial?
- Qual é a página exata para submissão, inscrição, programa, cronograma, contribuições ou proceedings?
- Quando cada informação foi verificada, qual foi a fonte e qual o grau de confiança?
- Quais eventos pertencem à América Latina e quais são apenas candidatos ainda não validados?

1.1 PÚBLICO-ALVO

- Pesquisadores, docentes e estudantes de pós-graduação em HEP/HECAP;
- Membros de colaborações experimentais e grupos de instrumentação;
- Organizadores de workshops, escolas, simpósios e conferências;
- Equipes que necessitam de uma agenda regional auditável e pesquisável.

1.2 PRINCÍPIOS DE PROJETO

- Fonte oficial antes de agregadores secundários;
- Separação entre estado do evento, submissão e inscrição;
- Preservação de divergências em vez de sobrescrita silenciosa;
- Coleta respeitosa, com robots.txt, atraso e limitação de concorrência;
- Rastreabilidade por URL, trecho de evidência, data de verificação e confiança;

- Estrutura modular baseada no Princípio da Responsabilidade Única.

2 EVOLUÇÃO DA IMPLEMENTAÇÃO POR PRIORIDADES

Etapa	Tema	Resultado
1	Estado temporal do evento	Classificação em futuro, em andamento, concluído ou desconhecido; radar padrão sem eventos finalizados.
2	Separação entre submissão e inscrição	Chamadas de trabalhos e janelas de inscrição passaram a ser entidades independentes.
3	Páginas internas e conflitos	Crawler passou a visitar chamadas, datas importantes, autores e inscrição, preservando evidências conflitantes.
4	Links específicos	Criação de recursos tipados para submissão, inscrição, programa, cronograma, contribuições e proceedings.
5	Auditoria e confiança	Exibição de fonte, trecho de evidência, data da última verificação, confiança e recência.
Expansão	América Latina	Filtro regional, catálogo regional separado e spiders de eventos e descoberta.
6	Histórico pesquisável	Ainda pendente: arquivo dedicado para eventos concluídos, mantendo materiais científicos acessíveis.

2.1 ESTRATÉGIA INCREMENTAL

A implementação foi conduzida por patches versionados e por pacotes completos consolidados. Cada etapa foi aplicada somente após:

1. backup da árvore vigente;
2. execução de patch em modo de simulação (`-dry-run`);
3. verificação de arquivos `.rej` e `.orig`;
4. execução da suíte de testes;

5. reconstrução dos contêineres afetados;
6. execução do seed e validação da API.

3 REQUISITOS FUNCIONAIS E NÃO FUNCIONAIS

3.1 REQUISITOS FUNCIONAIS

Código	Requisito
RF-01	Cadastrar e consultar eventos científicos com nome, sigla, datas, local, país, área e página oficial.
RF-02	Classificar automaticamente o estado temporal do evento.
RF-03	Representar múltiplas chamadas de submissão por evento.
RF-04	Representar diferentes fases de inscrição por evento.
RF-05	Oferecer filtros por texto, área, estado do evento, submissão, inscrição e região.
RF-06	Expor links específicos para atividades e materiais do evento.
RF-07	Coletar páginas internas e extrair datas e estados.
RF-08	Preservar conflitos entre fontes oficiais.
RF-09	Mostrar fonte, confiança e última verificação.
RF-10	Executar atualização periódica por fila de tarefas.
RF-11	Importar catálogo inicial de forma idempotente.
RF-12	Descobrir candidatos regionais sem publicação automática.

3.2 REQUISITOS NÃO FUNCIONAIS

Código	Requisito
RNF-01	Executar por Docker Compose com serviços isolados.
RNF-02	Manter persistência PostgreSQL e fila Redis.
RNF-03	Respeitar robots.txt e limitar carga sobre domínios externos.

Continua na próxima página

Código	**Requisito**
RNF-04	Ter testes unitários para regras temporais, extração, deduplicação, links e verificação.
RNF-05	Evitar invenção de prazos não encontrados.
RNF-06	Permitir ampliação para dezenas ou centenas de eventos sem limite fixo no modelo.
RNF-07	Separar responsabilidades entre API, interface, crawler, banco e tarefas.

4 ARQUITETURA DO SISTEMA

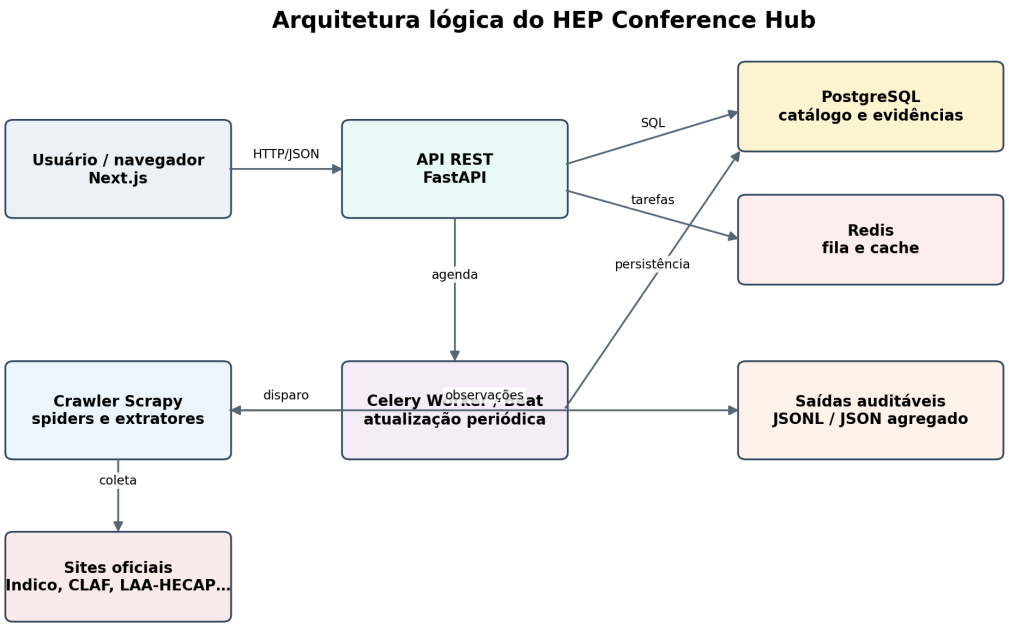


Figura 1 – Arquitetura lógica do portal.

A solução adota arquitetura distribuída em serviços, coordenada por Docker Compose. O navegador acessa o frontend Next.js, que consome a API FastAPI. A API persiste dados em PostgreSQL e despacha tarefas por Redis/Celery. O crawler Scrapy visita fontes oficiais, produz observações auditáveis e alimenta o processo de normalização e persistência.

4.1 SERVIÇOS PRINCIPAIS

Serviço	**Responsabilidade**	**Porta/Canal**
web	Interface web, filtros, cartões e painéis de auditoria.	3000/TCP
api	Endpoints REST, regras de negócio, schemas e persistência.	8000/TCP

Continua na próxima página

Serviço	**Responsabilidade**	**Porta/Canal**
postgres	Banco relacional e armazenamento persistente.	5432/TCP
redis	Broker para Celery e possível cache.	6379/TCP
worker	Execução assíncrona de atualização e processamento.	Fila Redis
beat	Agendamento periódico das tarefas.	Fila Redis
crawler	Coleta externa sob demanda ou acionada por tarefa.	HTTP/HTTPS externo

4.2 FLUXO DE DADOS

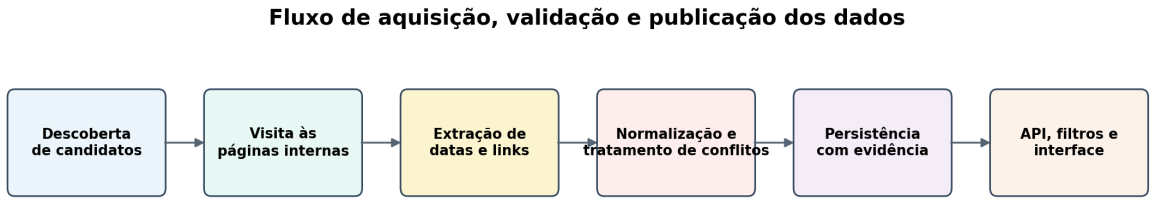


Figura 2 – Fluxo da descoberta à publicação.

5 TECNOLOGIAS UTILIZADAS

Camada	Tecnologia	Finalidade
Frontend	Next.js 15 + React + TypeScript	Renderização, formulários de busca, cartões e navegação.
Backend	FastAPI + Pydantic	API REST, validação de schemas e documentação automática.
Persistência	PostgreSQL 16 + SQLAlchemy	Modelo relacional, consultas e relacionamentos.
Fila	Redis 7 + Celery	Tarefas assíncronas e agendamento periódico.
Crawler	Scrapy 2.17 + Twisted 26.x	Navegação, respeito a robots.txt, throttling e pipelines.
Infraestrutura	Docker + Docker Compose	Ambiente reprodutível e isolamento de serviços.
Testes	unittest	Validação de regras de domínio e extratores.
Automação local	Makefile e scripts shell	Atalhos para build, seed, testes e crawling.

5.1 COMPATIBILIDADE SCRAPY/TWISTED

Durante a implementação, a combinação Scrapy 2.13.3 com Twisted 26.4.0 falhou ao importar uma API interna. A configuração consolidada passou a usar:

```
scrapy==2.17.0
Twisted>=26.4.0,<27
itemadapter==0.11.0
python-dateutil==2.9.0.post0
```

6 ORGANIZAÇÃO DO REPOSITÓRIO

```
hep-conference-hub/
|-- README.md
|-- Makefile
|-- docker-compose.yml
|-- .env
|-- apps/
|   |-- api/
|   |   |-- Dockerfile
|   |   |-- requirements.txt
|   |   `-- app/
|   |       |-- api/
|   |       |-- core/
|   |       |-- data/
|   |       |-- db/
|   |       |-- models/
|   |       |-- schemas/
|   |       |-- services/
|   |       |-- tasks/
|   |       |-- main.py
|   |       `-- seed.py
|   |-- web/
|   |   |-- app/
|   |   |-- components/
|   |   |-- Dockerfile
|   |   `-- package.json
|   `-- crawler/
|       |-- conference_crawler/
|       |   |-- extractors/
|       |   |-- pipelines/
|       |   `-- spiders/
|       |-- requirements.txt
|       `-- output/
|-- infra/
`-- tests/
```

6.1 RESPONSABILIDADES POR DIRETÓRIO

Diretório	**Responsabilidade**
apps/api/app/models	Entidades SQLAlchemy e relacionamentos.
apps/api/app/schemas	Contratos Pydantic expostos pela API.
apps/api/app/api	Rotas públicas e administrativas.
apps/api/app/services	Regras reutilizáveis, incluindo confiança e recência.
apps/api/app/data	Catálogos estruturados, como a expansão latino-americana.
apps/web/components	Componentes de interface, especialmente EventCard.
apps/crawler/.../extractors	Descoberta de páginas, datas, oportunidades e links.
apps/crawler/.../pipelines	Agregação, deduplicação e geração das saídas.
apps/crawler/.../spiders	Spiders específicos, genéricos e regionais.
tests	Testes unitários das regras e dos extratores.

7 MODELO DE DADOS

O modelo foi evoluído para evitar a representação simplificada de “um evento com uma única data de submissão”. Cada dimensão temporal e cada evidência possuem entidade própria.

7.1 EVENT

- Identidade: id, slug, nome, sigla e descrição;
- Tempo: início, fim e fuso horário;
- Localização: cidade, país e código do país;
- Classificação: área, tipo e estado temporal calculado;
- Origem: URL oficial e metadados de verificação;
- Relacionamentos: chamadas, inscrições e recursos.

7.2 CALLFORPAPERS / CHAMADAS

Representa uma chamada específica, por exemplo resumo oral, pôster, contribuição ou paper. O estado pode ser explícito mesmo sem uma data exata. Isso permite registrar “submissão encerrada” sem inventar o dia do encerramento.

7.3 REGISTRATIONWINDOW

Representa fases independentes de inscrição: antecipada, regular, tardia, presencial ou formulário geral. Cada fase pode possuir data de abertura, prazo, estado e página própria.

7.4 EVENTRESOURCE

Representa links semânticos e auditáveis. Os papéis previstos incluem:

```
submission
registration
programme
timetable
contributions
proceedings
```

```
important_dates
authors
payment
other
```

7.5 VERIFICATIONMIXIN

Entidades auditáveis compartilham campos como fonte, trecho de evidência, confiança, verificado e data da última verificação. Os níveis de confiança e recência são calculados para a resposta da API.

7.6 ESTADOS INDEPENDENTES

Dimensão	**Estados principais**
Evento	upcoming, ongoing, finished, cancelled, postponed, unknown
Submissão	not_announced, upcoming, open, extended, closed, unknown
Inscrição	not_announced, upcoming, open, closed, unknown
Confiança	high, medium, low, unknown
Recência	current, aging, stale, unknown

8 API REST

A API FastAPI expõe o catálogo em JSON e permite filtros combináveis. A documentação interativa normalmente fica disponível em `/docs`.

8.1 ENDPOINTS PRINCIPAIS

Método e rota	**Finalidade**
GET /health	Verificação de saúde da API.
GET /api/v1/events	Listagem paginada com filtros.
GET /api/v1/events/{slug}	Detalhamento de um evento.
GET /api/v1/admin/...	Indicadores administrativos e revisão.

8.2 FILTROS DE CONSULTA

```
q=<texto>
event_status=upcoming|ongoing|finished|active|all
submission_status=open|closed|unknown|all
registration_status=open|closed|unknown|all
area=<categoria>
region=latin-america|other|unknown
include_finished=true|false
limit=<número>
offset=<número>
```

8.3 EXEMPLO DE CONSULTA REGIONAL

```
curl -s \
  'http://localhost:8000/api/v1/events?region=latin-america&include_finished=true&
    limit=30' | \
  docker compose exec -T api python -m json.tool
```

8.4 ESTRUTURA RESUMIDA DA RESPOSTA

```
{
  "slug": "ichep-2026",
  "acronym": "ICHEP 2026",
  "event_status": "upcoming",
  "region": "latin-america",
  "calls": [...],
  "registrations": [...],
  "resources": [...],
  "confidence_score": 0.95,
  "confidence_level": "high",
  "verification_freshness": "current",
  "last_verified_at": "2026-07-26T..."
}
```

9 FRONTEND WEB

O frontend Next.js apresenta um radar de oportunidades. A página principal envia os filtros pela URL, permitindo compartilhamento e recarregamento do estado da pesquisa.

9.1 ELEMENTOS DE INTERFACE

- Campo de busca textual;
- Filtros de estado temporal, submissão, inscrição, área e região;
- Botão Buscar e opção para limpar filtros;
- Cartões com sigla, nome, local, período, estados e links específicos;
- Indicadores de confiança e recência;
- Painel recolhível “Fontes e auditoria dos dados”.

9.2 EVENTCARD

O componente `EventCard.tsx` concentra a apresentação do evento. Ele evita inferências indevidas: “prazo não cadastrado” é diferente de “submissão aberta”; “inscrição regular encerrada” não significa necessariamente que toda modalidade de inscrição esteja encerrada.

9.3 EXEMPLO DE APRESENTAÇÃO

```
Evento futuro
Submissão encerrada
Inscrição regular encerrada
Confiança alta * 95%
Verificação recente

Evento: 30/07/2026 a 05/08/2026
Submissão de resumos: encerrada
Inscrição regular encerrada em 23/07/2026

Página oficial | Chamada de resumos | Programa | Cronograma
```

10 CRAWLER E EXTRAÇÃO DE INFORMAÇÕES

O crawler foi construído em Scrapy com extratores especializados. O objetivo não é simplesmente copiar texto, mas produzir observações estruturadas, auditáveis e vinculadas à página exata.

10.1 CONFIGURAÇÕES RESPONSÁVEIS

```
ROBOTSTXT_OBEY = True
AUTOTHROTTLE_ENABLED = True
CONCURRENT_REQUESTS_PER_DOMAIN = 2
DOWNLOAD_DELAY = 1.5
DEPTH_LIMIT = 2
USER_AGENT = "HEPConferenceHubBot/0.1 (+contato-do-projeto)"
```

10.2 DESCOBERTA SEMÂNTICA DE PÁGINAS

O módulo `page_discovery.py` classifica links por função. Exemplos: chamada de resumos, datas importantes, inscrição, autores, programa, proceedings e newsletter. A navegação permanece restrita ao domínio oficial ou ao prefixo confiável do evento em uma plataforma Indico.

10.3 EXTRAÇÃO DE PRAZOS

O extrator identifica candidatos rotulados, preservando tipo, data, horário, fuso, estado, URL, trecho e confiança. Datas sem rótulo suficiente são ignoradas para evitar falsos positivos.

10.4 CONFLITOS

Quando páginas oficiais divergem, os valores são mantidos como evidências conflitantes. O sistema não escolhe silenciosamente uma data. Esse comportamento foi usado em casos como diferenças entre “Important Dates” e formulários Indico.

10.5 SPIDERS

Spider	**Finalidade**
ichep_2026	Coleta específica do ICHEP e páginas internas.
event_site	Coletor genérico parametrizado por URL e identificador.
latin_america_events	Percorre o catálogo regional verificado.
latin_america_discovery	Descobre candidatos em fontes regionais, sem publicação automática.

10.6 SAÍDAS

```
output/pages.jsonl
output/events_aggregated.json
output/latin_america_pages.jsonl
output/latin_america/events_aggregated.json
output/latin_america_candidates.jsonl
```

11 PROCESSAMENTO ASSÍNCRONO

Celery separa atualizações demoradas do ciclo HTTP da API. O worker executa tarefas; o beat agenda rotinas. Redis atua como broker. Essa separação evita que uma consulta do usuário precise esperar a coleta externa.

11.1 CUIDADOS OPERACIONAIS

- Limitar a concorrência do worker em máquinas com pouca memória;
- Executar o worker com usuário não root em ambiente de produção;
- Verificar se os módulos de tarefas estão registrados;
- Acompanhar logs de worker e beat separadamente;
- Configurar `vm.overcommit_memory=1` quando recomendado pelo Redis.

12 CATÁLOGO E EXPANSÃO PARA A AMÉRICA LATINA

A expansão regional adicionou um filtro calculado a partir do código do país, sem nova coluna no banco. O catálogo regional foi isolado em `apps/api/app/data/latin_america_2026.py`, mantendo o seed responsável apenas pela persistência.

12.1 EVENTOS CENTRAIS CADASTRADOS

Evento	**País/cidade**	**Categoria**
ICHEP 2026	Brasil — Natal	Conferência internacional de HEP
SILAFAE 2026	Colômbia — Bogotá	Simpósio latino-americano de HEP
PHENOEXP 2026	Brasil — São Paulo	Fenomenologia e experimentos
RPC 2026	Brasil — Rio de Janeiro	Detectores gasosos e instrumentação
Gamma Connection 2026	Chile — Santiago	Astropartículas e raios gama
PIPI Meeting II	Argentina — La Plata	Altas energias e objetos compactos
Advances in Quantum Gravity & Strings	Argentina — La Plata	HEP teórica, cordas e gravitação
RADPyC 2026	México — Cidade do México	Partículas e campos; evento histórico

12.2 FONTES DE DESCOBERTA

- LAA-HECAP: agenda regional de altas energias, cosmologia e astropartículas;
- CLAF: agenda ampla de eventos científicos latino-americanos;
- Instâncias Indico de universidades e laboratórios regionais;
- Páginas oficiais de institutos e organizadores.

12.3 REGRA DE PUBLICAÇÃO

Candidatos encontrados em agendas regionais não são publicados automaticamente. Primeiro devem ser validados em uma página oficial com informações mínimas de identidade, datas e localização. A separação entre descoberta e publicação reduz spam e eventos incorretos.

13 AUDITORIA, CONFIANÇA E RASTREABILIDADE

A prioridade 5 tornou visível a origem de cada informação. O sistema calcula classificações, mas preserva os dados brutos usados na decisão.

13.1 CONFIANÇA

Faixa	**Classificação**
0,90 a 1,00	Alta
0,70 a 0,89	Média
Abaixo de 0,70	Baixa
Sem pontuação	Desconhecida

13.2 RECÊNCIA

Idade da verificação	**Classificação**
Até 7 dias	Recente / current
8 a 30 dias	Rever em breve / aging
Mais de 30 dias	Desatualizada / stale
Sem data	Desconhecida / unknown

13.3 EVIDÊNCIA MÍNIMA

- URL da fonte;
- trecho de texto relevante;
- função da página;
- data e hora da última verificação;

- pontuação e nível de confiança;
- estado de verificação e possíveis conflitos.

14 TESTES E GARANTIA DA QUALIDADE

A suíte consolidada chegou a 61 testes após a expansão latino-americana. Os testes cobrem regras determinísticas e extratores. O número deve ser confirmado no repositório atual antes de qualquer release.

14.1 GRUPOS DE TESTES

Grupo	**Exemplos**
Estado do evento	futuro, em andamento inclusivo, evento de um dia, concluído e desconhecido
Submissão	estado explícito sem prazo e separação de chamadas
Inscrição	antes da abertura, dentro da janela e após o prazo
Deduplicação	siglas semelhantes e eventos distintos
Descoberta de páginas	classificação de Indico, restrição de domínio e descarte de links irrelevantes
Prazos	fases, múltiplos resumos, datas sem rótulo e conflitos
Recursos	papéis e links específicos
Verificação	limiares de confiança e recência
Região	classificação por país e filtros latino-americanos

14.2 COMANDO DE TESTE

```
docker compose run --rm --no-deps \
  -v "$PWD/apps/api/app:/app/app:ro" \
  -v "$PWD/apps/crawler:/app/crawler:ro" \
  -v "$PWD/tests:/app/tests:ro" \
  api \
  sh -lc 'PYTHONPATH=/app:/app/crawler python -m unittest discover -s /app/tests -v'
```

14.3 CRITÉRIOS DE ACEITAÇÃO

- Nenhum arquivo `.rej` ou `.orig` após a aplicação de mudanças;

- Todos os testes concluídos com `OK`;
- Build Next.js sem erro de tipos;
- Endpoint `/health` respondendo com status ok;
- Seed executado sem duplicação;
- Resposta detalhada contendo calls, registrations, resources e metadados de verificação.

15 DOCKER, CONFIGURAÇÃO E IMPLANTAÇÃO

15.1 VARIÁVEIS DE AMBIENTE

```
COMPOSE_PROJECT_NAME=hep-conference-hub
DATABASE_URL=postgresql+psycopg://conference:conference@postgres:5432/conference_hub
REDIS_URL=redis://redis:6379/0
```

Regra importante: dentro dos contêineres, os hosts são os nomes dos serviços (`postgres` e `redis`), não `localhost`.

15.2 CONSTRUÇÃO E SUBIDA

```
docker compose config -q
docker compose up --build -d
sleep 8
docker compose ps
curl http://localhost:8000/health
```

15.3 SEED

```
docker compose exec api python -m app.seed
```

O seed deve ser idempotente: atualiza registros conhecidos e evita duplicações.

15.4 PRESERVAÇÃO DO BANCO

Durante atualizações de código, deve-se evitar `docker compose down -v`, pois essa opção remove volumes. O procedimento normal é reconstruir os serviços afetados e manter o volume PostgreSQL.

15.5 RECONSTRUÇÃO SELETIVA

```
docker compose build --no-cache api web
docker compose up -d --force-recreate api web
```

16 OPERAÇÃO DIÁRIA

16.1 VERIFICAÇÃO DE SERVIÇOS

```
docker compose ps
docker compose logs api --tail=100
docker compose logs worker --tail=100
docker compose logs beat --tail=100
curl http://localhost:8000/health
```

16.2 CONSULTA DE EVENTOS LATINO-AMERICANOS

```
curl -s \
  'http://localhost:8000/api/v1/events?region=latin-america&include_finished=true&
    limit=30' | \
  docker compose exec -T api python -c '
import json, sys
payload = json.load(sys.stdin)
print("Total:", payload["total"])
for event in payload["items"]:
    print(event["event_status"], event.get("acronym"), event.get("city"))
'
```

16.3 AMBIENTE LOCAL DO CRAWLER

```
cd apps/crawler
python -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
python -m scrapy list
```

16.4 COLETA REGIONAL

```
python -m scrapy crawl latin_america_events
python -m scrapy crawl latin_america_discovery
python -m json.tool output/latin_america/events_aggregated.json
python -m json.tool --json-lines output/latin_america_candidates.jsonl
```

17 PROBLEMAS ENCONTRADOS E CORREÇÕES

Problema	**Causa**	**Correção consolidada**
Conflitos de portas 3000/8000/6379	Contêineres de projetos Compose antigos ainda ativos.	Identificar por porta, remover contêineres antigos e fixar COMPOSE_PROJECT_NAME.
API não resolvia via `postgres`	Rede Docker inconsistente.	Derrubar serviços, podar rede não utilizada, subir banco/Redis e depois API.
Redis apontava para localhost	Variável inadequada para ambiente em contêiner.	Usar redis://redis:6379/0.
Scrapy falhava em `_setAcceptableProtocols`	Versões incompatíveis de Scrapy e Twisted.	Atualizar para Scrapy 2.17 e Twisted 26.x.
Arquivo agregado inexistente	Crawler abortou antes da primeira requisição.	Corrigir dependências e executar novamente.
Patch aplicado no diretório errado	Comando executado em apps/crawler em vez da raiz.	Executar patch em hep-conference-hub com -p1.
Patch parcialmente aplicado	Árvore divergente gerou hunks rejeitados.	Restaurar pacote consolidado e validar ausência de `.rej`.
Next.js: variável freshness ausente	Trecho de declaração rejeitado e trecho de uso aplicado.	Substituir a árvore pela versão consolidada da prioridade 5.
`python` apontava para .venv removido	Terminal manteve PATH do ambiente antigo após troca da pasta.	Executar deactivate, hash -r e recriar .venv.
rsync tentou copiar `/`	Variável SRC vazia.	Validar `test -n "$SRC"` e presença do docker-compose antes da cópia.

17.1 PROCEDIMENTO SEGURO PARA SUBSTITUIÇÃO DA ÁRVORE

```
test -n "$SRC" || { echo "SRC vazia"; exit 1; }
test -f "$SRC/docker-compose.yml" || exit 1
test -d "$SRC/apps" || exit 1
rsync -a --exclude='.env' --exclude='.venv' --exclude='node_modules' "$SRC/" ./hep-
    conference-hub/
```

18 SEGURANÇA, ÉTICA E CONFORMIDADE

- Respeitar robots.txt e termos de uso de cada site;
- Usar um User-Agent identificável com endereço real de contato;
- Evitar concorrência agressiva e coletas repetidas sem necessidade;
- Não publicar automaticamente candidatos sem validação oficial;
- Não armazenar dados pessoais desnecessários;
- Registrar fonte e trecho para permitir correção e contestação;
- Usar segredos fortes e não versionar `.env` em repositório público;
- Executar contêineres com usuários não privilegiados em produção;
- Aplicar HTTPS e proxy reverso antes de exposição pública.

18.1 RISCOS DE DADOS

Risco	**Mitigação**
Prazo desatualizado	Indicador de recência e revisão periódica.
Divergência entre páginas	Preservação de conflitos e múltiplas evidências.
Evento falso ou irrelevante	Descoberta separada da publicação.
Mudança de HTML	Extratores semânticos, testes e revisão manual.
Sobrecarga do site de origem	Delay, throttling e baixa concorrência.

19 LIMITAÇÕES ATUAIS E ROADMAP

19.1 LIMITAÇÕES

- O catálogo ainda depende de seeds e spiders específicos para vários eventos;
- Mudanças de HTML podem exigir atualização de extratores;
- O crawler local exige ambiente virtual próprio quando executado fora do Docker;
- A migração de schema ainda se apoia em criação automática para parte das mudanças; produção deve adotar Alembic;
- A autenticação administrativa e o fluxo editorial ainda precisam ser fortalecidos;
- A prioridade 6 — arquivo histórico pesquisável — não foi concluída na versão documentada.

19.2 PRIORIDADE 6

A etapa seguinte deve retirar eventos concluídos do radar de oportunidades e criar um arquivo histórico pesquisável. O histórico deverá manter programa, contribuições, apresentações, proceedings e evidências, além de permitir filtros por ano, país, área e tipo de evento.

19.3 MELHORIAS RECOMENDADAS

1. Introduzir Alembic para migrações versionadas;
2. Criar painel editorial com aprovação, rejeição e resolução de conflitos;
3. Automatizar importação do JSON agregado para a API com transação e auditoria;
4. Adicionar testes de integração e testes ponta a ponta com Playwright;
5. Configurar proxy reverso, HTTPS, monitoramento e backups;
6. Criar newsletter e alertas personalizados por área, país e prazo;
7. Implementar deduplicação probabilística para eventos encontrados em fontes diferentes;
8. Ampliar fontes para outras regiões e colaborações científicas.

Appendices

A SEQUÊNCIA DE INSTALAÇÃO LIMPA

```
git clone <repositorio> hep-conference-hub
cd hep-conference-hub
cp .env.example .env
# Ajustar DATABASE_URL e REDIS_URL

docker compose config -q
docker compose up --build -d postgres redis
sleep 6
docker compose up -d api
sleep 5
curl http://localhost:8000/health
docker compose up -d worker beat web
docker compose exec api python -m app.seed
```

B CHECKLIST DE RELEASE

- Backup do banco e do `.env` concluído;
- Nenhum `.rej` ou `.orig` presente;
- Suíte de testes aprovada;
- Build da API e do frontend aprovado;
- Healthcheck da API aprovado;
- Seed idempotente executado;
- Filtros testados no navegador;
- Crawler executado em amostra controlada;
- Fontes e datas verificadas;
- Logs de worker e beat sem erros críticos.

C GLOSSÁRIO

Termo	**Definição**
HEP	High Energy Physics — Física de Altas Energias.
HECAP	High Energy, Cosmology and Astroparticle Physics.
Indico	Plataforma de gestão de eventos usada por CERN e diversas instituições.
Seed	Rotina idempotente que cria ou atualiza o catálogo inicial.
Spider	Componente Scrapy responsável pela navegação e coleta.
Pipeline	Etapa que processa, agrega e grava itens coletados.
Broker	Sistema intermediário de mensagens; no projeto, Redis.
Freshness	Classificação da idade da última verificação.
Confidence	Pontuação de confiabilidade da informação.
Resource	Link tipado para uma função específica do evento.

D REFERÊNCIA RÁPIDA DE COMANDOS

Objetivo	**Comando**
Ver serviços	docker compose ps
Ver saúde	curl http://localhost:8000/health
Executar seed	docker compose exec api python -m app.seed
Executar testes	docker compose run –rm –no-deps ... python -m unittest discover ...
Listar spiders	python -m scrapy list
Coletar América Latina	python -m scrapy crawl latin_america_events
Descobrir candidatos	python -m scrapy crawl latin_america_discovery
Ver logs da API	docker compose logs api –tail=100
Recriar frontend	docker compose build –no-cache web
Abrir portal	http://localhost:3000

Fim da documentação técnica — versão 1.0