HEP CONFERENCE HUB

Documentação técnica completa do portal

Congressos, workshops e escolas em Física de Altas Energias

Arquitetura, implementação, coleta de dados, auditoria, implantação e expansão para a América Latina

Responsável pelo projeto: Nelson Cevidanes Nascimento de Assis

Versão documentada: prioridades 1 a 5 e expansão latino-americana

Data de referência: 26 de julho de 2026

2026

CONTROLE DO DOCUMENTO

Item	Descrição
Título	Documentação técnica do HEP Conference Hub
Versão	1.0
Data de referência	26/07/2026
Estado funcional	Portal em execução com API, frontend, banco, fila, crawler e catálogo latino-americano
Escopo coberto	Prioridades 1–5, expansão regional e procedimentos operacionais
Pendência estrutural	Prioridade 6: arquivo histórico pesquisável de eventos concluídos

Nota de rastreabilidade. Este documento consolida a arquitetura, as decisões e os procedimentos efetivamente desenvolvidos durante a implementação. Alguns detalhes operacionais podem variar conforme novas alterações no repositório; os comandos de validação apresentados devem ser usados para confirmar o estado real da instalação.

SUMÁRIO

Controle do documento 1

1 VISÃO GERAL E OBJETIVOS 6
1.1 Público-alvo 6
1.2 Princípios de projeto 6

2 EVOLUÇÃO DA IMPLEMENTAÇÃO POR PRIORIDADES 8
2.1 Estratégia incremental 8

3 REQUISITOS FUNCIONAIS E NÃO FUNCIONAIS 10
3.1 Requisitos funcionais 10
3.2 Requisitos não funcionais 10

4 ARQUITETURA DO SISTEMA 12

4.1 Serviços principais . . . 12
4.2 Fluxo de dados . . . 13

5 TECNOLOGIAS UTILIZADAS . . . 14
5.1 Compatibilidade Scrapy/Twisted . . . 14

6 ORGANIZAÇÃO DO REPOSITÓRIO . . . 15
6.1 Responsabilidades por diretório . . . 15

7 MODELO DE DADOS . . . 17
7.1 Event . . . 17
7.2 CallForPapers / chamadas . . . 17
7.3 RegistrationWindow . . . 17
7.4 EventResource . . . 17
7.5 VerificationMixin . . . 18
7.6 Estados independentes . . . 18

8 API REST . . . 19
8.1 Endpoints principais . . . 19
8.2 Filtros de consulta . . . 19
8.3 Exemplo de consulta regional . . . 19
8.4 Estrutura resumida da resposta . . . 20

9 FRONTEND WEB . . . 21
9.1 Elementos de interface . . . 21
9.2 EventCard . . . 21
9.3 Exemplo de apresentação . . . 21

10 CRAWLER E EXTRAÇÃO DE INFORMAÇÕES . . . 22
10.1 Configurações responsáveis . . . 22
10.2 Descoberta semântica de páginas . . . 22
10.3 Extração de prazos . . . 22
10.4 Conflitos . . . 22
10.5 Spiders . . . 23
10.6 Saídas . . . 23

11 PROCESSAMENTO ASSÍNCRONO . . . 24
11.1 Cuidados operacionais . . . 24

12 CATÁLOGO E EXPANSÃO PARA A AMÉRICA LATINA . . . 25
12.1 Eventos centrais cadastrados . . . 25
12.2 Fontes de descoberta . . . 25

12.3 Regra de publicação 26

13 AUDITORIA, CONFIANÇA E RASTREABILIDADE 27
13.1 Confiança 27
13.2 Recência 27
13.3 Evidência mínima 27

14 TESTES E GARANTIA DA QUALIDADE 29
14.1 Grupos de testes 29
14.2 Comando de teste 29
14.3 Critérios de aceitação 29

15 DOCKER, CONFIGURAÇÃO E IMPLANTAÇÃO 31
15.1 Variáveis de ambiente 31
15.2 Construção e subida 31
15.3 Seed 31
15.4 Preservação do banco 31
15.5 Reconstrução seletiva 31

16 OPERAÇÃO DIÁRIA 32
16.1 Verificação de serviços 32
16.2 Consulta de eventos latino-americanos 32
16.3 Ambiente local do crawler 32
16.4 Coleta regional 32

17 PROBLEMAS ENCONTRADOS E CORREÇÕES 34
17.1 Procedimento seguro para substituição da árvore 35

18 SEGURANÇA, ÉTICA E CONFORMIDADE 36
18.1 Riscos de dados 36

19 LIMITAÇÕES ATUAIS E ROADMAP 37
19.1 Limitações 37
19.2 Prioridade 6 37
19.3 Melhorias recomendadas 37

Appendices 38

A – SEQUÊNCIA DE INSTALAÇÃO LIMPA 39

B – CHECKLIST DE RELEASE 40

C – GLOSSÁRIO 41

D – REFERÊNCIA RÁPIDA DE COMANDOS 42

LISTA DE ILUSTRAÇÕES

Figura 1 – Arquitetura lógica do portal. 12
Figura 2 – Fluxo da descoberta à publicação. 13

1 VISÃO GERAL E OBJETIVOS

O HEP Conference Hub é um portal destinado a localizar, organizar, acompanhar e auditar eventos científicos relacionados à Física de Altas Energias (HEP), calorimetria, detectores, aceleradores, computação científica, cosmologia e astropartículas. O sistema foi projetado para reduzir a dispersão de informações entre páginas oficiais, plataformas Indico, sites de institutos, agendas regionais e páginas de colaboração.

O portal procura responder, em uma única interface, às seguintes perguntas:

- Quais eventos estão próximos, em andamento ou concluídos?
- A submissão de resumos está aberta, encerrada ou ainda não anunciada?
- A inscrição está aberta e quais são os prazos antecipado, regular ou presencial?
- Qual é a página exata para submissão, inscrição, programa, cronograma, contribuições ou proceedings?
- Quando cada informação foi verificada, qual foi a fonte e qual o grau de confiança?
- Quais eventos pertencem à América Latina e quais são apenas candidatos ainda não validados?

1.1 PÚBLICO-ALVO

- Pesquisadores, docentes e estudantes de pós-graduação em HEP/HECAP;
- Membros de colaborações experimentais e grupos de instrumentação;
- Organizadores de workshops, escolas, simpósios e conferências;
- Equipes que necessitam de uma agenda regional auditável e pesquisável.

1.2 PRINCÍPIOS DE PROJETO

- Fonte oficial antes de agregadores secundários;
- Separação entre estado do evento, submissão e inscrição;
- Preservação de divergências em vez de sobrescrita silenciosa;
- Coleta respeitosa, com robots.txt, atraso e limitação de concorrência;
- Rastreabilidade por URL, trecho de evidência, data de verificação e confiança;

- Estrutura modular baseada no Princípio da Responsabilidade Única.

2 EVOLUÇÃO DA IMPLEMENTAÇÃO POR PRIORIDADES

Etapa	Tema	Resultado
1	Estado temporal do evento	Classificação em futuro, em andamento, concluído ou desconhecido; radar padrão sem eventos finalizados.
2	Separação entre submissão e inscrição	Chamadas de trabalhos e janelas de inscrição passaram a ser entidades independentes.
3	Páginas internas e conflitos	Crawler passou a visitar chamadas, datas importantes, autores e inscrição, preservando evidências conflitantes.
4	Links específicos	Criação de recursos tipados para submissão, inscrição, programa, cronograma, contribuições e proceedings.
5	Auditoria e confiança	Exibição de fonte, trecho de evidência, data da última verificação, confiança e recência.
Expansão	América Latina	Filtro regional, catálogo regional separado e spiders de eventos e descoberta.
6	Histórico pesquisável	Ainda pendente: arquivo dedicado para eventos concluídos, mantendo materiais científicos acessíveis.

2.1 ESTRATÉGIA INCREMENTAL

A implementação foi conduzida por patches versionados e por pacotes completos consolidados. Cada etapa foi aplicada somente após:

1. backup da árvore vigente;
2. execução de patch em modo de simulação (`-dry-run`);
3. verificação de arquivos `.rej` e `.orig`;
4. execução da suíte de testes;

5. reconstrução dos contêineres afetados;
6. execução do seed e validação da API.

3 REQUISITOS FUNCIONAIS E NÃO FUNCIONAIS

3.1 REQUISITOS FUNCIONAIS

Código	Requisito
RF-01	Cadastrar e consultar eventos científicos com nome, sigla, datas, local, país, área e página oficial.
RF-02	Classificar automaticamente o estado temporal do evento.
RF-03	Representar múltiplas chamadas de submissão por evento.
RF-04	Representar diferentes fases de inscrição por evento.
RF-05	Oferecer filtros por texto, área, estado do evento, submissão, inscrição e região.
RF-06	Expor links específicos para atividades e materiais do evento.
RF-07	Coletar páginas internas e extrair datas e estados.
RF-08	Preservar conflitos entre fontes oficiais.
RF-09	Mostrar fonte, confiança e última verificação.
RF-10	Executar atualização periódica por fila de tarefas.
RF-11	Importar catálogo inicial de forma idempotente.
RF-12	Descobrir candidatos regionais sem publicação automática.

3.2 REQUISITOS NÃO FUNCIONAIS

Código	Requisito
RNF-01	Executar por Docker Compose com serviços isolados.
RNF-02	Manter persistência PostgreSQL e fila Redis.
RNF-03	Respeitar robots.txt e limitar carga sobre domínios externos.

Continua na próxima página

Código	**Requisito**
RNF-04	Ter testes unitários para regras temporais, extração, deduplicação, links e verificação.
RNF-05	Evitar invenção de prazos não encontrados.
RNF-06	Permitir ampliação para dezenas ou centenas de eventos sem limite fixo no modelo.
RNF-07	Separar responsabilidades entre API, interface, crawler, banco e tarefas.

4 ARQUITETURA DO SISTEMA

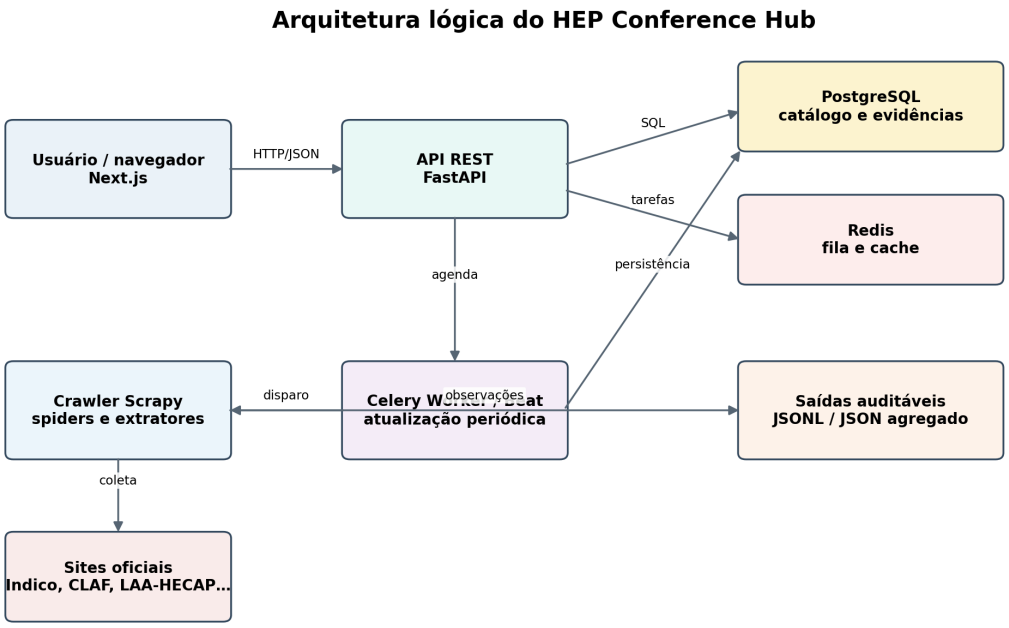


Figura 1 – Arquitetura lógica do portal.

A solução adota arquitetura distribuída em serviços, coordenada por Docker Compose. O navegador acessa o frontend Next.js, que consome a API FastAPI. A API persiste dados em PostgreSQL e despacha tarefas por Redis/Celery. O crawler Scrapy visita fontes oficiais, produz observações auditáveis e alimenta o processo de normalização e persistência.

4.1 SERVIÇOS PRINCIPAIS

Serviço	**Responsabilidade**	**Porta/Canal**
web	Interface web, filtros, cartões e painéis de auditoria.	3000/TCP
api	Endpoints REST, regras de negócio, schemas e persistência.	8000/TCP

Continua na próxima página

Serviço	**Responsabilidade**	**Porta/Canal**
postgres	Banco relacional e armazenamento persistente.	5432/TCP
redis	Broker para Celery e possível cache.	6379/TCP
worker	Execução assíncrona de atualização e processamento.	Fila Redis
beat	Agendamento periódico das tarefas.	Fila Redis
crawler	Coleta externa sob demanda ou acionada por tarefa.	HTTP/HTTPS externo

4.2 FLUXO DE DADOS

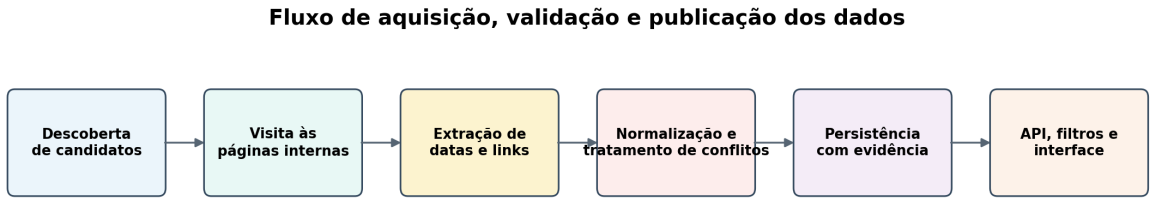


Figura 2 – Fluxo da descoberta à publicação.

5 TECNOLOGIAS UTILIZADAS

Camada	Tecnologia	Finalidade
Frontend	Next.js 15 + React + TypeScript	Renderização, formulários de busca, cartões e navegação.
Backend	FastAPI + Pydantic	API REST, validação de schemas e documentação automática.
Persistência	PostgreSQL 16 + SQLAlchemy	Modelo relacional, consultas e relacionamentos.
Fila	Redis 7 + Celery	Tarefas assíncronas e agendamento periódico.
Crawler	Scrapy 2.17 + Twisted 26.x	Navegação, respeito a robots.txt, throttling e pipelines.
Infraestrutura	Docker + Docker Compose	Ambiente reprodutível e isolamento de serviços.
Testes	unittest	Validação de regras de domínio e extratores.
Automação local	Makefile e scripts shell	Atalhos para build, seed, testes e crawling.

5.1 COMPATIBILIDADE SCRAPY/TWISTED

Durante a implementação, a combinação Scrapy 2.13.3 com Twisted 26.4.0 falhou ao importar uma API interna. A configuração consolidada passou a usar:

```
scrapy==2.17.0
Twisted>=26.4.0,<27
itemadapter==0.11.0
python-dateutil==2.9.0.post0
```

6 ORGANIZAÇÃO DO REPOSITÓRIO

```
hep-conference-hub/
|-- README.md
|-- Makefile
|-- docker-compose.yml
|-- .env
|-- apps/
|   |-- api/
|   |   |-- Dockerfile
|   |   |-- requirements.txt
|   |   `-- app/
|   |       |-- api/
|   |       |-- core/
|   |       |-- data/
|   |       |-- db/
|   |       |-- models/
|   |       |-- schemas/
|   |       |-- services/
|   |       |-- tasks/
|   |       |-- main.py
|   |       `-- seed.py
|   |-- web/
|   |   |-- app/
|   |   |-- components/
|   |   |-- Dockerfile
|   |   `-- package.json
|   `-- crawler/
|       |-- conference_crawler/
|       |   |-- extractors/
|       |   |-- pipelines/
|       |   `-- spiders/
|       |-- requirements.txt
|       `-- output/
|-- infra/
`-- tests/
```

6.1 RESPONSABILIDADES POR DIRETÓRIO

Diretório	**Responsabilidade**
apps/api/app/models	Entidades SQLAlchemy e relacionamentos.
apps/api/app/schemas	Contratos Pydantic expostos pela API.
apps/api/app/api	Rotas públicas e administrativas.
apps/api/app/services	Regras reutilizáveis, incluindo confiança e recência.
apps/api/app/data	Catálogos estruturados, como a expansão latino-americana.
apps/web/components	Componentes de interface, especialmente EventCard.
apps/crawler/.../extractors	Descoberta de páginas, datas, oportunidades e links.
apps/crawler/.../pipelines	Agregação, deduplicação e geração das saídas.
apps/crawler/.../spiders	Spiders específicos, genéricos e regionais.
tests	Testes unitários das regras e dos extratores.

7 MODELO DE DADOS

O modelo foi evoluído para evitar a representação simplificada de “um evento com uma única data de submissão”. Cada dimensão temporal e cada evidência possuem entidade própria.

7.1 EVENT

- Identidade: id, slug, nome, sigla e descrição;
- Tempo: início, fim e fuso horário;
- Localização: cidade, país e código do país;
- Classificação: área, tipo e estado temporal calculado;
- Origem: URL oficial e metadados de verificação;
- Relacionamentos: chamadas, inscrições e recursos.

7.2 CALLFORPAPERS / CHAMADAS

Representa uma chamada específica, por exemplo resumo oral, pôster, contribuição ou paper. O estado pode ser explícito mesmo sem uma data exata. Isso permite registrar “submissão encerrada” sem inventar o dia do encerramento.

7.3 REGISTRATIONWINDOW

Representa fases independentes de inscrição: antecipada, regular, tardia, presencial ou formulário geral. Cada fase pode possuir data de abertura, prazo, estado e página própria.

7.4 EVENTRESOURCE

Representa links semânticos e auditáveis. Os papéis previstos incluem:

```
submission
registration
programme
timetable
contributions
proceedings
```

```
important_dates
authors
payment
other
```

7.5 VERIFICATIONMIXIN

Entidades auditáveis compartilham campos como fonte, trecho de evidência, confiança, verificado e data da última verificação. Os níveis de confiança e recência são calculados para a resposta da API.

7.6 ESTADOS INDEPENDENTES

Dimensão	**Estados principais**
Evento	upcoming, ongoing, finished, cancelled, postponed, unknown
Submissão	not_announced, upcoming, open, extended, closed, unknown
Inscrição	not_announced, upcoming, open, closed, unknown
Confiança	high, medium, low, unknown
Recência	current, aging, stale, unknown

8 API REST

A API FastAPI expõe o catálogo em JSON e permite filtros combináveis. A documentação interativa normalmente fica disponível em `/docs`.

8.1 ENDPOINTS PRINCIPAIS

Método e rota	**Finalidade**
GET /health	Verificação de saúde da API.
GET /api/v1/events	Listagem paginada com filtros.
GET /api/v1/events/{slug}	Detalhamento de um evento.
GET /api/v1/admin/...	Indicadores administrativos e revisão.

8.2 FILTROS DE CONSULTA

```
q=<texto>
event_status=upcoming|ongoing|finished|active|all
submission_status=open|closed|unknown|all
registration_status=open|closed|unknown|all
area=<categoria>
region=latin-america|other|unknown
include_finished=true|false
limit=<número>
offset=<número>
```

8.3 EXEMPLO DE CONSULTA REGIONAL

```
curl -s \
  'http://localhost:8000/api/v1/events?region=latin-america&include_finished=true&
    limit=30' | \
  docker compose exec -T api python -m json.tool
```

8.4 ESTRUTURA RESUMIDA DA RESPOSTA

```
{
  "slug": "ichep-2026",
  "acronym": "ICHEP 2026",
  "event_status": "upcoming",
  "region": "latin-america",
  "calls": [...],
  "registrations": [...],
  "resources": [...],
  "confidence_score": 0.95,
  "confidence_level": "high",
  "verification_freshness": "current",
  "last_verified_at": "2026-07-26T..."
}
```

9 FRONTEND WEB

O frontend Next.js apresenta um radar de oportunidades. A página principal envia os filtros pela URL, permitindo compartilhamento e recarregamento do estado da pesquisa.

9.1 ELEMENTOS DE INTERFACE

- Campo de busca textual;
- Filtros de estado temporal, submissão, inscrição, área e região;
- Botão Buscar e opção para limpar filtros;
- Cartões com sigla, nome, local, período, estados e links específicos;
- Indicadores de confiança e recência;
- Painel recolhível “Fontes e auditoria dos dados”.

9.2 EVENTCARD

O componente `EventCard.tsx` concentra a apresentação do evento. Ele evita inferências indevidas: “prazo não cadastrado” é diferente de “submissão aberta”; “inscrição regular encerrada” não significa necessariamente que toda modalidade de inscrição esteja encerrada.

9.3 EXEMPLO DE APRESENTAÇÃO

```
Evento futuro
Submissão encerrada
Inscrição regular encerrada
Confiança alta * 95%
Verificação recente

Evento: 30/07/2026 a 05/08/2026
Submissão de resumos: encerrada
Inscrição regular encerrada em 23/07/2026

Página oficial | Chamada de resumos | Programa | Cronograma
```

10 CRAWLER E EXTRAÇÃO DE INFORMAÇÕES

O crawler foi construído em Scrapy com extratores especializados. O objetivo não é simplesmente copiar texto, mas produzir observações estruturadas, auditáveis e vinculadas à página exata.

10.1 CONFIGURAÇÕES RESPONSÁVEIS

```
ROBOTSTXT_OBEY = True
AUTOTHROTTLE_ENABLED = True
CONCURRENT_REQUESTS_PER_DOMAIN = 2
DOWNLOAD_DELAY = 1.5
DEPTH_LIMIT = 2
USER_AGENT = "HEPConferenceHubBot/0.1 (+contato-do-projeto)"
```

10.2 DESCOBERTA SEMÂNTICA DE PÁGINAS

O módulo `page_discovery.py` classifica links por função. Exemplos: chamada de resumos, datas importantes, inscrição, autores, programa, proceedings e newsletter. A navegação permanece restrita ao domínio oficial ou ao prefixo confiável do evento em uma plataforma Indico.

10.3 EXTRAÇÃO DE PRAZOS

O extrator identifica candidatos rotulados, preservando tipo, data, horário, fuso, estado, URL, trecho e confiança. Datas sem rótulo suficiente são ignoradas para evitar falsos positivos.

10.4 CONFLITOS

Quando páginas oficiais divergem, os valores são mantidos como evidências conflitantes. O sistema não escolhe silenciosamente uma data. Esse comportamento foi usado em casos como diferenças entre “Important Dates” e formulários Indico.

10.5 SPIDERS

Spider	**Finalidade**
ichep_2026	Coleta específica do ICHEP e páginas internas.
event_site	Coletor genérico parametrizado por URL e identificador.
latin_america_events	Percorre o catálogo regional verificado.
latin_america_discovery	Descobre candidatos em fontes regionais, sem publicação automática.

10.6 SAÍDAS

```
output/pages.jsonl
output/events_aggregated.json
output/latin_america_pages.jsonl
output/latin_america/events_aggregated.json
output/latin_america_candidates.jsonl
```

11 PROCESSAMENTO ASSÍNCRONO

Celery separa atualizações demoradas do ciclo HTTP da API. O worker executa tarefas; o beat agenda rotinas. Redis atua como broker. Essa separação evita que uma consulta do usuário precise esperar a coleta externa.

11.1 CUIDADOS OPERACIONAIS

- Limitar a concorrência do worker em máquinas com pouca memória;
- Executar o worker com usuário não root em ambiente de produção;
- Verificar se os módulos de tarefas estão registrados;
- Acompanhar logs de worker e beat separadamente;
- Configurar `vm.overcommit_memory=1` quando recomendado pelo Redis.

12 CATÁLOGO E EXPANSÃO PARA A AMÉRICA LATINA

A expansão regional adicionou um filtro calculado a partir do código do país, sem nova coluna no banco. O catálogo regional foi isolado em `apps/api/app/data/latin_america_2026.py`, mantendo o seed responsável apenas pela persistência.

12.1 EVENTOS CENTRAIS CADASTRADOS

Evento	**País/cidade**	**Categoria**
ICHEP 2026	Brasil — Natal	Conferência internacional de HEP
SILAFAE 2026	Colômbia — Bogotá	Simpósio latino-americano de HEP
PHENOEXP 2026	Brasil — São Paulo	Fenomenologia e experimentos
RPC 2026	Brasil — Rio de Janeiro	Detectores gasosos e instrumentação
Gamma Connection 2026	Chile — Santiago	Astropartículas e raios gama
PIPI Meeting II	Argentina — La Plata	Altas energias e objetos compactos
Advances in Quantum Gravity & Strings	Argentina — La Plata	HEP teórica, cordas e gravitação
RADPyC 2026	México — Cidade do México	Partículas e campos; evento histórico

12.2 FONTES DE DESCOBERTA

- LAA-HECAP: agenda regional de altas energias, cosmologia e astropartículas;
- CLAF: agenda ampla de eventos científicos latino-americanos;
- Instâncias Indico de universidades e laboratórios regionais;
- Páginas oficiais de institutos e organizadores.

12.3 REGRA DE PUBLICAÇÃO

Candidatos encontrados em agendas regionais não são publicados automaticamente. Primeiro devem ser validados em uma página oficial com informações mínimas de identidade, datas e localização. A separação entre descoberta e publicação reduz spam e eventos incorretos.

13 AUDITORIA, CONFIANÇA E RASTREABILIDADE

A prioridade 5 tornou visível a origem de cada informação. O sistema calcula classificações, mas preserva os dados brutos usados na decisão.

13.1 CONFIANÇA

Faixa	**Classificação**
0,90 a 1,00	Alta
0,70 a 0,89	Média
Abaixo de 0,70	Baixa
Sem pontuação	Desconhecida

13.2 RECÊNCIA

Idade da verificação	**Classificação**
Até 7 dias	Recente / current
8 a 30 dias	Rever em breve / aging
Mais de 30 dias	Desatualizada / stale
Sem data	Desconhecida / unknown

13.3 EVIDÊNCIA MÍNIMA

- URL da fonte;
- trecho de texto relevante;
- função da página;
- data e hora da última verificação;

- pontuação e nível de confiança;
- estado de verificação e possíveis conflitos.

14 TESTES E GARANTIA DA QUALIDADE

A suíte consolidada chegou a 61 testes após a expansão latino-americana. Os testes cobrem regras determinísticas e extratores. O número deve ser confirmado no repositório atual antes de qualquer release.

14.1 GRUPOS DE TESTES

Grupo	**Exemplos**
Estado do evento	futuro, em andamento inclusivo, evento de um dia, concluído e desconhecido
Submissão	estado explícito sem prazo e separação de chamadas
Inscrição	antes da abertura, dentro da janela e após o prazo
Deduplicação	siglas semelhantes e eventos distintos
Descoberta de páginas	classificação de Indico, restrição de domínio e descarte de links irrelevantes
Prazos	fases, múltiplos resumos, datas sem rótulo e conflitos
Recursos	papéis e links específicos
Verificação	limiares de confiança e recência
Região	classificação por país e filtros latino-americanos

14.2 COMANDO DE TESTE

```
docker compose run --rm --no-deps \
  -v "$PWD/apps/api/app:/app/app:ro" \
  -v "$PWD/apps/crawler:/app/crawler:ro" \
  -v "$PWD/tests:/app/tests:ro" \
  api \
  sh -lc 'PYTHONPATH=/app:/app/crawler python -m unittest discover -s /app/tests -v'
```

14.3 CRITÉRIOS DE ACEITAÇÃO

- Nenhum arquivo `.rej` ou `.orig` após a aplicação de mudanças;

- Todos os testes concluídos com `OK`;
- Build Next.js sem erro de tipos;
- Endpoint `/health` respondendo com status ok;
- Seed executado sem duplicação;
- Resposta detalhada contendo calls, registrations, resources e metadados de verificação.

15 DOCKER, CONFIGURAÇÃO E IMPLANTAÇÃO

15.1 VARIÁVEIS DE AMBIENTE

```
COMPOSE_PROJECT_NAME=hep-conference-hub
DATABASE_URL=postgresql+psycopg://conference:conference@postgres:5432/conference_hub
REDIS_URL=redis://redis:6379/0
```

Regra importante: dentro dos contêineres, os hosts são os nomes dos serviços (`postgres` e `redis`), não `localhost`.

15.2 CONSTRUÇÃO E SUBIDA

```
docker compose config -q
docker compose up --build -d
sleep 8
docker compose ps
curl http://localhost:8000/health
```

15.3 SEED

```
docker compose exec api python -m app.seed
```

O seed deve ser idempotente: atualiza registros conhecidos e evita duplicações.

15.4 PRESERVAÇÃO DO BANCO

Durante atualizações de código, deve-se evitar `docker compose down -v`, pois essa opção remove volumes. O procedimento normal é reconstruir os serviços afetados e manter o volume PostgreSQL.

15.5 RECONSTRUÇÃO SELETIVA

```
docker compose build --no-cache api web
docker compose up -d --force-recreate api web
```

16 OPERAÇÃO DIÁRIA

16.1 VERIFICAÇÃO DE SERVIÇOS

```
docker compose ps
docker compose logs api --tail=100
docker compose logs worker --tail=100
docker compose logs beat --tail=100
curl http://localhost:8000/health
```

16.2 CONSULTA DE EVENTOS LATINO-AMERICANOS

```
curl -s \
  'http://localhost:8000/api/v1/events?region=latin-america&include_finished=true&
    limit=30' | \
  docker compose exec -T api python -c '
import json, sys
payload = json.load(sys.stdin)
print("Total:", payload["total"])
for event in payload["items"]:
    print(event["event_status"], event.get("acronym"), event.get("city"))
'
```

16.3 AMBIENTE LOCAL DO CRAWLER

```
cd apps/crawler
python -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
python -m scrapy list
```

16.4 COLETA REGIONAL

```
python -m scrapy crawl latin_america_events
python -m scrapy crawl latin_america_discovery
python -m json.tool output/latin_america/events_aggregated.json
python -m json.tool --json-lines output/latin_america_candidates.jsonl
```

17 PROBLEMAS ENCONTRADOS E CORREÇÕES

Problema	**Causa**	**Correção consolidada**
Conflitos de portas 3000/8000/6379	Contêineres de projetos Compose antigos ainda ativos.	Identificar por porta, remover contêineres antigos e fixar COMPOSE_PROJECT_NAME.
API não resolvia via `postgres`	Rede Docker inconsistente.	Derrubar serviços, podar rede não utilizada, subir banco/Redis e depois API.
Redis apontava para localhost	Variável inadequada para ambiente em contêiner.	Usar redis://redis:6379/0.
Scrapy falhava em `_setAcceptableProtocols`	Versões incompatíveis de Scrapy e Twisted.	Atualizar para Scrapy 2.17 e Twisted 26.x.
Arquivo agregado inexistente	Crawler abortou antes da primeira requisição.	Corrigir dependências e executar novamente.
Patch aplicado no diretório errado	Comando executado em apps/crawler em vez da raiz.	Executar patch em hep-conference-hub com -p1.
Patch parcialmente aplicado	Árvore divergente gerou hunks rejeitados.	Restaurar pacote consolidado e validar ausência de `.rej`.
Next.js: variável freshness ausente	Trecho de declaração rejeitado e trecho de uso aplicado.	Substituir a árvore pela versão consolidada da prioridade 5.
`python` apontava para .venv removido	Terminal manteve PATH do ambiente antigo após troca da pasta.	Executar deactivate, hash -r e recriar .venv.
rsync tentou copiar `/`	Variável SRC vazia.	Validar `test -n "$SRC"` e presença do docker-compose antes da cópia.

17.1 PROCEDIMENTO SEGURO PARA SUBSTITUIÇÃO DA ÁRVORE

```
test -n "$SRC" || { echo "SRC vazia"; exit 1; }
test -f "$SRC/docker-compose.yml" || exit 1
test -d "$SRC/apps" || exit 1
rsync -a --exclude='.env' --exclude='.venv' --exclude='node_modules' "$SRC/" ./hep-
    conference-hub/
```

18 SEGURANÇA, ÉTICA E CONFORMIDADE

- Respeitar robots.txt e termos de uso de cada site;
- Usar um User-Agent identificável com endereço real de contato;
- Evitar concorrência agressiva e coletas repetidas sem necessidade;
- Não publicar automaticamente candidatos sem validação oficial;
- Não armazenar dados pessoais desnecessários;
- Registrar fonte e trecho para permitir correção e contestação;
- Usar segredos fortes e não versionar `.env` em repositório público;
- Executar contêineres com usuários não privilegiados em produção;
- Aplicar HTTPS e proxy reverso antes de exposição pública.

18.1 RISCOS DE DADOS

Risco	**Mitigação**
Prazo desatualizado	Indicador de recência e revisão periódica.
Divergência entre páginas	Preservação de conflitos e múltiplas evidências.
Evento falso ou irrelevante	Descoberta separada da publicação.
Mudança de HTML	Extratores semânticos, testes e revisão manual.
Sobrecarga do site de origem	Delay, throttling e baixa concorrência.

19 LIMITAÇÕES ATUAIS E ROADMAP

19.1 LIMITAÇÕES

- O catálogo ainda depende de seeds e spiders específicos para vários eventos;
- Mudanças de HTML podem exigir atualização de extratores;
- O crawler local exige ambiente virtual próprio quando executado fora do Docker;
- A migração de schema ainda se apoia em criação automática para parte das mudanças; produção deve adotar Alembic;
- A autenticação administrativa e o fluxo editorial ainda precisam ser fortalecidos;
- A prioridade 6 — arquivo histórico pesquisável — não foi concluída na versão documentada.

19.2 PRIORIDADE 6

A etapa seguinte deve retirar eventos concluídos do radar de oportunidades e criar um arquivo histórico pesquisável. O histórico deverá manter programa, contribuições, apresentações, proceedings e evidências, além de permitir filtros por ano, país, área e tipo de evento.

19.3 MELHORIAS RECOMENDADAS

1. Introduzir Alembic para migrações versionadas;
2. Criar painel editorial com aprovação, rejeição e resolução de conflitos;
3. Automatizar importação do JSON agregado para a API com transação e auditoria;
4. Adicionar testes de integração e testes ponta a ponta com Playwright;
5. Configurar proxy reverso, HTTPS, monitoramento e backups;
6. Criar newsletter e alertas personalizados por área, país e prazo;
7. Implementar deduplicação probabilística para eventos encontrados em fontes diferentes;
8. Ampliar fontes para outras regiões e colaborações científicas.

Appendices

A SEQUÊNCIA DE INSTALAÇÃO LIMPA

```
git clone <repositorio> hep-conference-hub
cd hep-conference-hub
cp .env.example .env
# Ajustar DATABASE_URL e REDIS_URL

docker compose config -q
docker compose up --build -d postgres redis
sleep 6
docker compose up -d api
sleep 5
curl http://localhost:8000/health
docker compose up -d worker beat web
docker compose exec api python -m app.seed
```

B CHECKLIST DE RELEASE

- Backup do banco e do `.env` concluído;
- Nenhum `.rej` ou `.orig` presente;
- Suíte de testes aprovada;
- Build da API e do frontend aprovado;
- Healthcheck da API aprovado;
- Seed idempotente executado;
- Filtros testados no navegador;
- Crawler executado em amostra controlada;
- Fontes e datas verificadas;
- Logs de worker e beat sem erros críticos.

C GLOSSÁRIO

Termo	**Definição**
HEP	High Energy Physics — Física de Altas Energias.
HECAP	High Energy, Cosmology and Astroparticle Physics.
Indico	Plataforma de gestão de eventos usada por CERN e diversas instituições.
Seed	Rotina idempotente que cria ou atualiza o catálogo inicial.
Spider	Componente Scrapy responsável pela navegação e coleta.
Pipeline	Etapa que processa, agrega e grava itens coletados.
Broker	Sistema intermediário de mensagens; no projeto, Redis.
Freshness	Classificação da idade da última verificação.
Confidence	Pontuação de confiabilidade da informação.
Resource	Link tipado para uma função específica do evento.

D REFERÊNCIA RÁPIDA DE COMANDOS

Objetivo	**Comando**
Ver serviços	docker compose ps
Ver saúde	curl http://localhost:8000/health
Executar seed	docker compose exec api python -m app.seed
Executar testes	docker compose run –rm –no-deps ... python -m unittest discover ...
Listar spiders	python -m scrapy list
Coletar América Latina	python -m scrapy crawl latin_america_events
Descobrir candidatos	python -m scrapy crawl latin_america_discovery
Ver logs da API	docker compose logs api –tail=100
Recriar frontend	docker compose build –no-cache web
Abrir portal	http://localhost:3000

Fim da documentação técnica — versão 1.0